

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ
імені ІГОРЯ СІКОРСЬКОГО»

Навчально-науковий інститут прикладного системного аналізу

ЗВІТ

про виконання лабораторної роботи №1
з дисципліни «Обробка надвеликих масивів даних»

на тему: **«Розподілена обробка даних в Apache Hadoop та Apache Hive»**

Виконав:
студент групи КІ-61мп
Гавлицький Іван

Перевірив:
Пишнограєв Іван Олександрович

ЗМІСТ

МЕТА РОБОТИ	3
1 ОПИС ЗАДАЧІ ТА ВХІДНИХ ДАНИХ	3
1.1 Постановка задачі	3
1.2 Програмне середовище	4
1.3 Вхідні дані	5
2 ХІД РОБОТИ	6
2.1 Підготовка та завантаження даних у HDFS	6
2.2 Створення таблиць в Apache Hive	7
2.3 Аналітичні запити	12
2.4 Партиціювання	18
2.5 Бакетинг	21
2.6 Задача WordCount	24
3 АНАЛІЗ РЕЗУЛЬТАТІВ ПОРІВНЯННЯ ЧАСУ ВИКОНАННЯ ЗА- ПИТІВ	26
4 АНАЛІЗ РОЗПОДІЛУ СЛІВ МІЖ ВИХІДНИМИ ФАЙЛАМИ . . .	28
ВИСНОВКИ	31
СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ	32
ДОДАТОК А. ПРОГРАМНИЙ КОД	34
ДОДАТОК Б. СКРИПТ ЗАВАНТАЖЕННЯ ДАНИХ	34

МЕТА РОБОТИ

Ознайомитися з архітектурою та принципами роботи розподіленої файлової системи HDFS; набути практичних навичок роботи з командним рядком Hadoop; вивчити основи створення сховищ даних в Apache Hive (DDL, DML операції); опанувати методи оптимізації зберігання даних (Partitioning, Bucketing) та виконати задачу MapReduce.

1 ОПИС ЗАДАЧІ ТА ВХІДНИХ ДАНИХ

1.1 Постановка задачі

Відповідно до завдання необхідно:

1. завантажити CSV-файли юридичних осіб (UO) та фізичних осіб-підприємців (FOP) скриптом на Python і розмістити їх у HDFS (/tables_data/UO, /tables_data/FOP);
2. створити в Apache Hive зовнішні таблиці `uo_table` і `fop_table` поверх цих даних з використанням `OpenCSVSerde`;
3. виконати аналітичні запити: підрахунок записів з порівнянням часу з традиційною СКБД, нумерацію юридичних осіб у межах адреси віконною функцією `row_number()` та з'єднання таблиць за адресою реєстрації;
4. реалізувати партиціювання (таблиця `uo_part` за станом юридичної особи) та бакетинг (10 бакетів за кодом ЄДРПОУ), порівняти час виконання запитів зі звичайною таблицею;
5. виконати задачу WordCount з вбудованої бібліотеки прикладів Hadoop з різною кількістю редюсерів і проаналізувати розподіл слів між вихідними файлами.

1.2 Програмне середовище

Кластер розгорнуто локально в Docker (Docker Compose). Склад сервісів наведено в табл. 1.1. Hive налаштовано на виконання запитів рушієм MapReduce (`hive.execution.engine=mr`) у кластері YARN, сховище даних Hive (`/user/hive/warehouse`) розташоване в HDFS. Оскільки кластер має один DataNode, фактор реплікації встановлено рівним 1. Для порівняння з традиційною СКБД до кластера додано PostgreSQL 17.

Таблиця 1.1 – Сервіси кластера

Сервіс	Образ Docker	Призначення
namenode	bde2020/hadoop-namenode	простір імен HDFS, відображення файлів на блоки
datanode	bde2020/hadoop-datanode	зберігання блоків даних
resourcemanager	bde2020/hadoop-resourcemanager	планування задач YARN
nodemanager	bde2020/hadoop-nodemanager	виконання контейнерів map/reduce
historyserver	bde2020/hadoop-historyserver	історія завершених задач
hive-server	apache/hive:3.1.3	HiveServer2, метастор Derby
postgres	postgres:17	реляційна СКБД для порівняння

Усі кроки лабораторної роботи виконано в ноутбучі Jupyter (див. додаток А): він запускає кластер, завантажує дані, виконує команди HDFS, запити HiveQL та задачу MapReduce. Стан кластера після запуску показано на рис. 1.1.

```
$ docker compose --progress quiet -f infra/docker-compose.yml up -d --wait --wait-timeout 300
$ docker compose -f infra/docker-compose.yml ps --format 'table {{.Name}}'      '{{.Status}}'
NAME                                STATUS
datanode                            Up 32 seconds (healthy)
historyserver                        Up 30 seconds (healthy)
hive-server                          Up 30 seconds
namenode                            Up 30 seconds (healthy)
nodemanager                          Up 31 seconds (healthy)
postgres                             Up 31 seconds (healthy)
resource-manager                     Up 31 seconds (healthy)
```

Рисунок 1.1 – Контейнери кластера після запуску

1.3 Вхідні дані

Основне джерело – Єдиний державний реєстр юридичних осіб, фізичних осіб-підприємців та громадських формувань [1]. Поточні відкриті дані реєстру на порталі data.gov.ua не містять адрес і видів діяльності (КВЕД), без яких неможливі запити завдання 3, тому використано останнє вивантаження, що їх містить, – від 08.04.2022 (архів XML у кодуванні Windows-1251, 461 МБ). Скрипт `download_data.py` (додаток Б) завантажує архів, перевіряє контрольну суму SHA-256 і потоково перетворює XML на CSV у кодуванні UTF-8. Структуру отриманих файлів наведено в табл. 1.2.

Таблиця 1.2 – Структура вхідних даних

Файл	Записів	Розмір	Поля
UO.csv	1 853 363	1,2 ГБ	name, edrpou, address, boss, founders, kved, stan
FOP.csv	5 792 593	2,0 ГБ	fio, address, kved, stan

Поле `stan` (стан суб'єкта) має 7 значень для UO та 6 для FOP, наприклад «zareestrovano», «priypineno», «v stanі priypinenня». Для задачі WordCount використано логи HDFS реального Hadoop-кластера – набір `HDFS_v1` з колекції Loghub [2]: 11,2 млн рядків, 1,5 ГБ.

2 ХІД РОБОТИ

2.1 Підготовка та завантаження даних у HDFS

Результат виконання скрипта завантаження наведено на рис. 2.1: перетворення XML на CSV тривало 75 с для UO та 107 с для FOP.

```
$ /home/nuinashco/Projects/iasa-bigdata/.venv/bin/python scripts/download_data.py
[download] https://web.archive.org/web/20220413051017id_/https://nais.gov.ua/files/general/2022/04/08/20220408144948-25.zip
[download] saved /home/nuinashco/Projects/iasa-bigdata/labs/001-hadoop-and-hive/data/raw/edr_2022-04-08.zip (461 MB)
[convert] UO.csv: 1,853,363 rows in 75s
[convert] FOP.csv: 5,792,593 rows in 107s
```

Рисунок 2.1 – Завантаження та перетворення даних скриптом `download_data.py`

Папка з CSV-файлами змонтована в контейнер `namenode` як `/data`. Перед записом у HDFS виконано команду `hdfs dfsadmin -safemode wait`: після запуску `NameNode` файлова система перебуває в режимі лише для читання (`safe mode`), доки `DataNode` не повідомлять про свої блоки. Далі створено директорії, завантажено файли та перевірено їх наявність (рис. 2.2).

```
$ hdfs dfs -mkdir -p /tables_data/UO /tables_data/FOP
$ hdfs dfs -put -f /data/UO.csv /tables_data/UO/
$ hdfs dfs -put -f /data/FOP.csv /tables_data/FOP/
$ hdfs dfs -ls -h /tables_data/UO /tables_data/FOP
Found 1 items
-rw-r--r--  1 root supergroup      1.1 G 2026-10-07 21:53 /tables_data/UO/UO.csv
Found 1 items
-rw-r--r--  1 root supergroup      1.9 G 2026-10-07 21:53 /tables_data/FOP/FOP.csv
```

Рисунок 2.2 – Створення директорій, завантаження файлів і перевірка командою `hdfs dfs -ls`

Розбиття файлу на блоки показує команда `hdfs fsck` (рис. 2.3): файл `UO.csv` розміром 1 200 075 063 байти зберігається у 9 блоках – 8 повних по 128 МБ (134 217 728 байт) і останньому неповному; кожен блок має одну репліку (`Live_repl=1`).

```
$ hdfs fsck /tables_data/UO/UO.csv -files -blocks
Connecting to namenode via http://namenode:9870/fsck?ugi=root&files=1&blocks=1&path=%2Ftables_data%2FUO%2FUO.csv
FCK started by root (auth:SIMPLE) from /172.18.0.7 for path /tables_data/UO/UO.csv at Wed Oct 07 21:53:14 UTC 2026
/tables_data/UO/UO.csv 1200075063 bytes, replicated: replication=1, 9 block(s): OK
0. BP-482417747-172.18.0.7-1791409663714:blk_1073741830_1006 len=134217728 Live_repl=1
1. BP-482417747-172.18.0.7-1791409663714:blk_1073741831_1007 len=134217728 Live_repl=1
2. BP-482417747-172.18.0.7-1791409663714:blk_1073741832_1008 len=134217728 Live_repl=1
3. BP-482417747-172.18.0.7-1791409663714:blk_1073741833_1009 len=134217728 Live_repl=1
4. BP-482417747-172.18.0.7-1791409663714:blk_1073741834_1010 len=134217728 Live_repl=1
5. BP-482417747-172.18.0.7-1791409663714:blk_1073741835_1011 len=134217728 Live_repl=1
6. BP-482417747-172.18.0.7-1791409663714:blk_1073741836_1012 len=134217728 Live_repl=1
7. BP-482417747-172.18.0.7-1791409663714:blk_1073741837_1013 len=134217728 Live_repl=1
8. BP-482417747-172.18.0.7-1791409663714:blk_1073741838_1014 len=126333239 Live_repl=1

Status: HEALTHY
Number of data-nodes: 1
Number of racks: 1
Total dirs: 0
Total symlinks: 0
```

Рисунок 2.3 – Блоки файлу `UO.csv` у HDFS

2.2 Створення таблиць в Apache Hive

Зовнішні таблиці описують CSV-файли в HDFS, не копіюючи їх (лістинги 2.1, 2.2). Порівняно з прикладом у завданні виправлено значення `quoteChar` ("`\`" замість "`"`") та додано властивість `skip.header.line.count`, оскільки CSV-файли містять рядок заголовка.

Лістинг 2.1 – Створення зовнішньої таблиці `uo_table`

```
CREATE EXTERNAL TABLE IF NOT EXISTS uo_table (
    name      STRING,
    edrpou    STRING,
    address   STRING,
    boss      STRING,
    founders  STRING,
    kved      STRING,
```

```

        stan      STRING
    )
ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.OpenCSVSerde'
WITH SERDEPROPERTIES (
    "separatorChar" = ",",
    "quoteChar"     = "\""
)
STORED AS TEXTFILE
LOCATION '/tables_data/UO'
TBLPROPERTIES ("skip.header.line.count" = "1")

```

Лістинг 2.2 – Створення зовнішньої таблиці fop_table

```

CREATE EXTERNAL TABLE IF NOT EXISTS fop_table (
    fio      STRING,
    address  STRING,
    kved     STRING,
    stan     STRING
)
ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.OpenCSVSerde'
WITH SERDEPROPERTIES (
    "separatorChar" = ",",
    "quoteChar"     = "\""
)
STORED AS TEXTFILE
LOCATION '/tables_data/FOP'
TBLPROPERTIES ("skip.header.line.count" = "1")

```

Коректність створення таблиць перевірено запитом `SELECT * ... LIMIT 10` (рис. 2.4, 2.5): значення в лапках, що містять коми, розібрано правильно, кирилиця відображається коректно. Такі запити Ніве виконує без запуску MapReduce (fetch task), тому вони тривають менше 3 с.

[2.57s] SELECT * FROM uo_table LIMIT 10

	name	edrpou	address	boss	founders	kved	stan
0	АКЦІОНЕРНЕ ТОВАРИСТВО "ДАШУКІВСЬКІ БЕНТОНІТИ"	00223941	Україна, 19330, Черкаська обл., Лисянський р-н, село Дашуківка	БЕСАРАБ ВОЛОДИМИР МИХАЙЛОВИЧ	АКЦІОНЕРИ, розмір частки - 13719925,00 грн.	08.12 Добування піску, гравію, глин і каоліну	зареєстровано
1	ВІДДІЛ ОСВІТИ, ОХОРОНИ ЗДОРОВ'Я, КУЛЬТУРИ, СПОРТУ ЗОЛОТОНІСЬКОЇ РАЙОННОЇ ДЕР...	02147061	Україна, 19702, Черкаська обл., місто Золотоноша, ВУЛИЦЯ БЛАГОВИЩЕНСЬКА, буд...	Дехтярук Інна Григорівна		84.12 Регулювання у сферах охорони здоров'я, освіти, культури та інших соціа...	зареєстровано
2	ТОВАРИСТВО З ОБМЕЖЕНОЮ ВІДПОВІДАЛЬНІСТЮ "ПРОМЕКС"	30904152	Україна, 19322, , С. ПОЧАПИНЦІ, ЛИСЯНСЬКИЙ РАЙОН, ЧЕРКАСЬКА ОБЛАСТЬ				припинено
3	ВІДКРИТЕ АКЦІОНЕРНЕ ТОВАРИСТВО "ЛИСЯНСЬКИЙ МОЛОКОЗАВОД"	01530272	Україна, 19300, ПРОВ. БУЖАНСЬКИЙ, 32, СМТ ЛИСЯНКА, ЛИСЯНСЬКИЙ РАЙОН, ЧЕРКАСЬ...				припинено
4	КОМУНАЛЬНЕ ПІДПРИЄМСТВО "ЛИСЯНСЬКЕ ВИРОБНИЧЕ УПРАВЛІННЯ ЖИТЛОВО- КОМУНАЛЬНОГО...	03357079	Україна, 19300, ВУЛ.КІЇВСЬКА, 86, СМТ ЛИСЯНКА, ЛИСЯНСЬКИЙ РАЙОН, ЧЕРКАСЬКА О...				припинено
5	"ЧЕСНІВСЬКЕ"	32242050	Україна, 19310, Черкаська обл., Лисянський р-н, село Чеснівка	ГЕРМАН ПАВЛО ІВАНОВИЧ	ГЕРМАН ПАВЛО ІВАНОВИЧ, розмір частки - 0,00 грн.	01.11.0 ВИРОЩУВАННЯ ЗЕРНОВИХ ТА ТЕХНІЧНИХ КУЛЬТУР	припинено
6	ТОВАРИСТВО З ОБМЕЖЕНОЮ ВІДПОВІДАЛЬНІСТЮ " АРБАТ - АГРО "	31100636	Україна, 19100, ВУЛ. ВІННИЦЬКА, 27, М. МОНАСТИРИЩЕ, МОНАСТИРИЩЕНСЬКИЙ РАЙОН,...				припинено
7	ЛИСЯНСЬКЕ ПІДПРИЄМСТВО ТЕПЛОВИХ МЕРЕЖ	14215690	Україна, 19300, ВУЛ.ЧЕРВОНОАРМІЙСЬКА, 2, СМТ. ЛИСЯНКА, ЛИСЯНСЬКИЙ РАЙОН, ЧЕР...	ДЕРКАЧ ПЕТРО МИХАЙЛОВИЧ	ЛИСЯНСЬКА СЕЛИЩНА РАДА, розмір частки - 0,00 грн.	40.3 ПОСТАЧАННЯ ПАРИ ТА ГАРЯЧОЇ ВОДИ	припинено
8	МАР'ЯНІВСЬКИЙ ЗАКЛАД ЗАГАЛЬНОЇ СЕРЕДНЬОЇ ОСВІТИ	33335512	Україна, 19344, Черкаська обл., Лисянський р-н, селище Мар'янівка, ВУЛИЦЯ ШК...	ГАВРИЛЮК ІРИНА МИКОЛАІВНА	ВИНОГРАДСЬКА СІЛЬСЬКА РАДА	85.31 Загальна середня освіта	зареєстровано
9	МАНЬКІВСЬКА ДИТЯЧА ШКОЛА МИСТЕЦТВ	24355966	Україна, 20101, Черкаська обл., Уманський р-н, селище міського типу Маньківк...	БАС СТАНІСЛАВ АНАТОЛІЙОВИЧ	МАНЬКІВСЬКА СЕЛИЩНА РАДА	85.52 Освіта у сфері культури	зареєстровано

Рисунок 2.4 – Перші 10 рядків таблиці uo_table

```
[0.24s] SELECT * FROM fop_table LIMIT 10
```

	fio	address	kved	stan
0	ФЕДОРЕНКО КОСТЯНТИН ВОЛОДИМИРОВИЧ	Україна, 15300, Чернігівська обл., Корюківський р-н, місто Корюківка, вул.Па...	49.41 Вантажний автомобільний транспорт	зареєстровано
1	Рябченко Юрій Максимович	Україна, 12601, Житомирська обл., Житомирський р-н, селище міського типу Бру...	47.11 Роздрібна торгівля в неспеціалізованих магазинах переважно продуктами ...	зареєстровано
2	ТЕЛІШЕВСЬКА ОЛЬГА БОГДАНІВНА	Україна, 79034, Львівська обл., місто Львів, вул. Стуса В., будинок 24, квар...	69.10 Діяльність у сфері права	зареєстровано
3	ТИМОШЕНКО ДМІТРИЙ ЮРІЙОВИЧ	Україна, 03041, місто Київ, вулиця Блакитного, будинок 8	56.10 Діяльність ресторанів, надання послуг мобільного харчування	припинено
4	ШИМКІВ ІРИНА АНАТОЛІІВНА	Україна, 39601, Полтавська обл., місто Кременчук, вулиця Європейська, будино...	46.33 Оптова торгівля молочними продуктами, яйцями, харчовими оліями та жирами	зареєстровано
5	Корж Єлизавета Володимирівна	Україна, 02232, місто Київ, вул.Бальзака Оноре де, будинок 5-А, квартира 155	47.76 Роздрібна торгівля квітами, рослинами, насінням, добривами, домашніми ...	зареєстровано
6	Цуркан Анжела Борисівна	Україна, 66502, Одеська обл., Подільський р-н, селище міського типу Любашівк...	96.09 Надання інших індивідуальних послуг, н.в.і.у.	зареєстровано
7	Думбрава Тамара Іванівна	Україна, 65016, Одеська обл., місто Одеса, пров.Компасний, будинок 1-А, квар...	47.73 Роздрібна торгівля фармацевтичними товарами в спеціалізованих магазинах	зареєстровано
8	Шавеко Євген Ігорович	Україна, 68421, Одеська обл., Болградський р-н, село Теплиця, вул.Верхня, бу...	47.79 Роздрібна торгівля уживаними товарами в магазинах	зареєстровано
9	Головчук Сергій Федорович	Україна, 65000, Одеська обл., місто Одеса, вулиця Героїв Прикордонників, буд...	62.01 Комп'ютерне програмування	зареєстровано

Рисунок 2.5 – Перші 10 рядків таблиці fop_table

Команда `DESCRIBE FORMATTED` (рис. 2.6) підтверджує тип таблиці `EXTERNAL_TABLE`, розташування даних `hdfs://namenode:9000/tables_data/UO` та використання `OpenCSVSerde`. Усі колонки мають тип `string`: `OpenCSVSerde` не підтримує інших типів.

```
[0.12s] DESCRIBE FORMATTED uo_table
```

	col_name	data_type	comment
0	# col_name	data_type	comment
1	name	string	from deserializer
2	edrpou	string	from deserializer
3	address	string	from deserializer
4	boss	string	from deserializer
5	founders	string	from deserializer
6	kved	string	from deserializer
7	stan	string	from deserializer
8			
9	# Detailed Table Information		
10	Database:	default	
11	OwnerType:	USER	
12	Owner:	hive	
13	CreateTime:	Wed Oct 07 21:53:15 UTC 2026	
14	LastAccessTime:	UNKNOWN	
15	Retention:	0	
16	Location:	hdfs://namenode:9000/tables_data/UO	
17	Table Type:	EXTERNAL_TABLE	
18	Table Parameters:		
19		EXTERNAL	TRUE
20		bucketing_version	2
21		numFiles	1
22		skip.header.line.count	1
23		totalSize	1200075063
24		transient_lastDdlTime	1791409995
25			
26	# Storage Information		
27	SerDe Library:	org.apache.hadoop.hive.serde2.OpenCSVSerde	
28	InputFormat:	org.apache.hadoop.mapred.TextInputFormat	
29	OutputFormat:	org.apache.hadoop.hive.ql.io.HiveIgnoreKeyTextOutputFormat	
30	Compressed:	No	
31	Num Buckets:	-1	
32	Bucket Columns:	[]	
33	Sort Columns:	[]	
34	Storage Desc Params:		
35		quoteChar	\"
36		separatorChar	,

Рисунок 2.6 – Метадані таблиці uo_table

2.3 Аналітичні запити

2.3.1 Агрегація даних

Для порівняння з традиційною СКБД ті самі CSV-файли завантажено в PostgreSQL командою COPY (лістинг 2.3); завантаження тривало 19,6 с для UO та 33,7 с для FOP.

Лістинг 2.3 – Завантаження даних у PostgreSQL

```
CREATE TABLE IF NOT EXISTS uo (
    name      TEXT,
    edrpou    TEXT,
    address   TEXT,
    boss      TEXT,
    founders  TEXT,
    kved      TEXT,
    stan      TEXT
);

CREATE TABLE IF NOT EXISTS fop (
    fio       TEXT,
    address   TEXT,
    kved      TEXT,
    stan      TEXT
);

TRUNCATE uo, fop;

COPY uo FROM '/data/UO.csv' WITH (FORMAT csv, HEADER true);
COPY fop FROM '/data/FOP.csv' WITH (FORMAT csv, HEADER true);

VACUUM ANALYZE uo;
VACUUM ANALYZE fop;
```

Hive може відповідати на COUNT (*) зі статистики таблиці в метасторі, не читаючи дані, тому перед вимірюваннями цю оптимізацію вимкнено (SET hive.compute.query.using.stats=false). Запит (лістинг 2.4) ви-

конано тричі для кожної таблиці в обох системах; результати наведено на рис. 2.7 і в табл. 2.1.

Лістинг 2.4 – Підрахунок кількості записів

```
SELECT
    COUNT(*) AS rows_count

FROM
    uo_table
```

```
[0.01s] SET hive.compute.query.using.stats=false
[30.72s, HDFS read 1.1 GB] SELECT COUNT(*) AS rows_count FROM uo_table
[36.77s, HDFS read 1.9 GB] SELECT COUNT(*) AS rows_count FROM fop_table
median 28.18s (runs: 28.18, 27.55, 29.82), HDFS read 1.1 GB | SELECT COUNT(*) AS rows_count FROM uo_t
able
median 37.16s (runs: 36.18, 38.31, 37.16), HDFS read 1.9 GB | SELECT COUNT(*) AS rows_count FROM fop_
table
median 0.15s (runs: 0.17, 0.15, 0.14) | SELECT COUNT(*) AS rows_count FROM uo
median 0.29s (runs: 0.29, 0.28, 0.30) | SELECT COUNT(*) AS rows_count FROM fop
```

	rows	Hive, s	PostgreSQL, s
UO	1853363	28.177506	0.148209
FOP	5792593	37.161205	0.289515

Рисунок 2.7 – Час виконання COUNT(*) у Hive та PostgreSQL

Таблиця 2.1 – Час виконання COUNT(*), медіана трьох запусків

Таблиця	Записів	Прочитано	Hive, c	PostgreSQL, c
UO	1 853 363	1,1 ГБ	28,18	0,15
FOP	5 792 593	1,9 ГБ	37,16	0,29

2.3.2 Нумерація юридичних осіб у межах адреси

Представлення `uo_numbered` нумерує юридичних осіб у межах кожної адреси за зростанням коду ЄДРПОУ (лістинг 2.5). Найбільший номер на адресі дорівнює кількості зареєстрованих на ній юридичних осіб, що дозволяє знайти адреси масової реєстрації (лістинг 2.6, рис. 2.8).

Лістинг 2.5 – Нумерація юридичних осіб у межах адреси

```
CREATE OR REPLACE VIEW uo_numbered AS  
SELECT  
    name,  
    edrpou,  
    address,  
    ROW_NUMBER() OVER (PARTITION BY address ORDER BY edrpou) AS rn  
  
FROM  
    uo_table
```

Лістинг 2.6 – Адреси масової реєстрації

```
SELECT  
    address,  
    MAX(rn) AS companies  
  
FROM  
    uo_numbered  
  
GROUP BY address  
  
ORDER BY companies DESC  
  
LIMIT 20
```

[96.00s, HDFS read 1.5 GB] SELECT address, MAX(rn) AS companies FROM uo_numbered GROUP BY address ORDER BY companies DESC LIMIT 20

	address	companies
0	Україна, 04050, місто Київ, ВУЛИЦЯ МЕЛЬНИКОВА, будинок 12	2187
1	Україна, 01014, місто Київ, ВУЛИЦЯ ЗВІРИНЕЦЬКА, будинок 63	1444
2	Україна, 04119, місто Київ, ВУЛИЦЯ ЗООЛОГІЧНА, будинок 4А, офіс 139	729
3	Україна, 03124, місто Київ, ВУЛИЦЯ МИКОЛИ ВАСИЛЕНКА, будинок 7-А	643
4	Україна, 03127, місто Київ, ПРОСПЕКТ 40-РІЧЧЯ ЖОВТНЯ, будинок 120, корпус 1	627
5	Україна, 02099, місто Київ, ВУЛИЦЯ ЯЛТИНСЬКА, будинок 5-Б	553
6	Україна, 04205, місто Київ, ПРОСПЕКТ ОБОЛОНСЬКИЙ, будинок 23-А	518
7	Україна, 01133, місто Київ, БУЛЬВАР ЛЕСІ УКРАЇНКИ, будинок 26	509
8	Україна, 03127, місто Київ, ПРОСПЕКТ 40-РІЧЧЯ ЖОВТНЯ, будинок 100/2	508
9	Україна, 04080, місто Київ, ВУЛИЦЯ КИРИЛІВСЬКА, будинок 82, офіс 256	502
10	Україна, 01103, місто Київ, ВУЛИЦЯ КІКВІДЗЕ, будинок 13	473
11	Україна, 02099, місто Київ, ВУЛИЦЯ БОРИСПІЛЬСЬКА, будинок 9	451
12	Україна, 04112, місто Київ, ВУЛИЦЯ ОРАНЖЕРЕЙНА, будинок 3	443
13	Україна, 04119, місто Київ, ВУЛИЦЯ ЗООЛОГІЧНА, будинок 4-А, офіс 139	440
14	Україна, 03189, місто Київ, ВУЛИЦЯ ВІЛЬЯМСА АКАДЕМІКА, будинок 6-Д, офіс 43	401
15	Україна, 01025, місто Київ, ВУЛИЦЯ ВОЛОДИМИРСЬКА, будинок 7, офіс 1	382
16	Україна, 04053, місто Київ, ВУЛИЦЯ АРТЕМА, будинок 21	376
17	Україна, 03061, місто Київ, ВУЛИЦЯ ШЕПЕЛЕВА МИКОЛИ, будинок 6	350
18	Україна, 03062, місто Київ, ПРОСПЕКТ ПЕРЕМОГИ, будинок 67	340
19	Україна, 04053, місто Київ, ВУЛИЦЯ СІЧОВИХ СТРІЛЬЦІВ, будинок 21	337

Рисунок 2.8 – Адреси з найбільшою кількістю юридичних осіб

Усі 20 адрес масової реєстрації розташовані в Києві; лідер – вул. Мельникова, 12 (2187 юридичних осіб). Запит виконувався 96 с: віконна функція потребує сортування всіх 1,85 млн записів за адресою. Помітна також проблема якості даних: «ВУЛИЦЯ ЗООЛОГІЧНА, будинок 4А, офіс 139» (729) і «будинок 4-А, офіс 139» (440) – одна адреса, записана по-різному. Перші юридичні особи на адресі-лідері наведено на рис. 2.9 (лістинг 2.7).

Лістинг 2.7 – Юридичні особи на адресі масової реєстрації

```

SELECT
    rn,
    edrpou,
    name

FROM
    uo_numbered

WHERE 1=1
    AND address = 'Україна, 04050, місто Київ, ВУЛИЦЯ МЕЛЬНИКОВА, будинок 12'

```

```
ORDER BY rn
```

```
LIMIT 20
```

```
[61.25s, HDFS read 1.1 GB] SELECT rn, edrpou, name FROM uo_numbered WHERE 1=1 AND address = 'Україна, 04050, місто Київ, вул. Мельникова, 12'
```

	rn	edrpou	name
0	1	13474886	ТОВАРИСТВО З ОБМЕЖЕНОЮ ВІДПОВІДАЛЬНІСТЮ "СИНТОП"
1	2	13668159	ЗАКРИТЕ АКЦІОНЕРНЕ ТОВАРИСТВО "СПЕЦ-ІНВЕСТ"
2	3	13668780	ТОВАРИСТВО З ОБМЕЖЕНОЮ ВІДПОВІДАЛЬНІСТЮ "КОМПАН-УКРАЇНА"
3	4	13674036	ПРИВАТНЕ ПІДПРИЄМСТВО "КОСІБА"
4	5	13678525	ТОВАРИСТВО З ОБМЕЖЕНОЮ ВІДПОВІДАЛЬНІСТЮ "СІРІУС"
5	6	13680031	ТОВАРИСТВО З ОБМЕЖЕНОЮ ВІДПОВІДАЛЬНІСТЮ "НАУКОВО-ТЕХНІЧНИЙ ЦЕНТР "СКІФ", ЛТД"
6	7	14279974	МАЛЕ ПІДПРИЄМСТВО "НЦ - ПРИКЛАДНА МАТЕМАТИКА"
7	8	14348132	ПРИВАТНЕ ПІДПРИЄМСТВО "СЕМЕНІВ"
8	9	14355646	ТОВАРИСТВО З ОБМЕЖЕНОЮ ВІДПОВІДАЛЬНІСТЮ "ФОБОС-2"
9	10	14360311	ТОВАРИСТВО З ОБМЕЖЕНОЮ ВІДПОВІДАЛЬНІСТЮ "НІМЕЦЬКО-УКРАЇНСЬКА ФІРМА "ДУАЦ"
10	11	14361457	ВСЕУКРАЇНСЬКА ЕРГОНОМІЧНА АСОЦІАЦІЯ
11	12	16288049	ТОВАРИСТВО З ОБМЕЖЕНОЮ ВІДПОВІДАЛЬНІСТЮ "КОМПАНІЯ "СУПУТНИКІНВЕСТ"
12	13	16289480	ТОВАРИСТВО З ОБМЕЖЕНОЮ ВІДПОВІДАЛЬНІСТЮ "ПНЕВМОСТІЙКА"
13	14	16297522	ТОВАРИСТВО З ОБМЕЖЕНОЮ ВІДПОВІДАЛЬНІСТЮ "ГАЗКОМПРОЕКТ"
14	15	16471262	КОМУНАЛЬНЕ ПІДПРИЄМСТВО "ЦЕНТР МАРКЕТИНГУ" ШЕВЧЕНКІВСЬКОГО РАЙОНУ М.КИЄВА"
15	16	16477804	МАЛЕ ПРИВАТНЕ ПІДПРИЄМСТВО "СОФІЯ"
16	17	16479803	ПРИВАТНЕ ПІДПРИЄМСТВО "ВІКТОРІЯ"
17	18	19020465	ТОВАРИСТВО З ОБМЕЖЕНОЮ ВІДПОВІДАЛЬНІСТЮ "МІЖНАРОДНИЙ ІНСТИТУТ СОЦІОЛІКІ"
18	19	19124199	ТОВАРИСТВО З ОБМЕЖЕНОЮ ВІДПОВІДАЛЬНІСТЮ "ХІОЛ ЛТД"
19	20	19133637	ТОВАРИСТВО З ОБМЕЖЕНОЮ ВІДПОВІДАЛЬНІСТЮ "ІТ ГЛОРІЯ"

Рисунок 2.9 – Перші 20 юридичних осіб на вул. Мельникова, 12

2.3.3 З'єднання таблиць за адресою реєстрації

З'єднання `uo_table` і `fop_table` за адресою (лістинги 2.8, 2.9) знаходить адреси, на яких зареєстровані і юридичні особи, і ФОП. Таких адрес 122 917, пар «юридична особа – ФОП» – 1 870 748 (рис. 2.10).

Лістинг 2.8 – Кількість спільних адрес і пар

```
SELECT
    COUNT(DISTINCT u.address) AS shared_addresses,
    COUNT(*) AS pairs
FROM
    uo_table AS u
```

INNER JOIN

```
fop_table AS f
ON u.address = f.address
```

[101.70s, HDFS read 3.0 GB] SELECT COUNT(DISTINCT u.address) AS shared_addresses, COUNT(*) AS pairs FROM uo_table AS u INNER JOIN fop_table AS f ON u.address = f.address

	shared_addresses	pairs
0	122917	1870748

Рисунок 2.10 – Розмір з'єднання UO та FOP за адресою

Лістинг 2.9 – Адреси з найбільшою кількістю пар

```
SELECT
    u.address,
    COUNT(DISTINCT u.edrpou) AS uo_count,
    COUNT(DISTINCT f.fio) AS fop_count,
    COUNT(*) AS pairs

FROM
    uo_table AS u

INNER JOIN
    fop_table AS f
    ON u.address = f.address

GROUP BY u.address

ORDER BY pairs DESC

LIMIT 20
```

[140.47s, HDFS read 3.3 GB] SELECT u.address, COUNT(DISTINCT u.edrpou) AS uo_count, COUNT(DISTINCT f.fio) AS fop_count, COUNT...

	address	uo_count	fop_count	pairs
0	Україна, Кіровоградська обл., місто Кіровоград(п)	210	992	208530
1	Україна, 61024, Харківська обл., місто Харків, ВУЛИЦЯ ПУШКІНСЬКА, будинок 79/1	60	361	22560
2	Україна, 59052, Чернівецька обл., Сторожинецький р-н, село Великий Кучурів	23	835	20217
3	Україна, 60014, Чернівецька обл., Хотинський р-н, село Клішківці	32	511	17728
4	Україна, 79000, Львівська обл., місто Львів	98	162	15876
5	Україна, 60321, Чернівецька обл., Новоселицький р-н, село Бояни	40	367	15600
6	Україна, 59222, Чернівецька обл., Вижницький р-н, село Іспас	26	554	15366
7	Україна, 60309, Чернівецька обл., Новоселицький р-н, село Маршинці	21	653	15183
8	Україна, 60312, Чернівецька обл., Новоселицький р-н, село Рідківці	30	409	14070
9	Україна, 60313, Чернівецька обл., Новоселицький р-н, село Магала	23	498	12420
10	Україна, 65023, Одеська обл., місто Одеса, ВУЛИЦЯ ЛЬВА ТОЛСТОГО, будинок 7	24	344	8472
11	Україна, 60023, Чернівецька обл., Хотинський р-н, село Колінківці	25	316	8425
12	Україна, 60412, Чернівецька обл., Глибоцький р-н, село Чагор	17	460	8330
13	Україна, 59230, Чернівецька обл., Вижницький р-н, село Лукавці	24	315	7896
14	Україна, 78640, Івано-Франківська обл., Косівський р-н, село Космач	22	332	7876
15	Україна, 59206, Чернівецька обл., Вижницький р-н, село Черногузи	20	350	7623
16	Україна, 59236, Чернівецька обл., Вижницький р-н, село Мигове	16	430	7376
17	Україна, 66112, Одеська обл., Балтський р-н, село Пужайкове	54	122	7260
18	Україна, 59040, Чернівецька обл., Сторожинецький р-н, село Михальча	19	337	6954
19	Україна, 60413, Чернівецька обл., Глибоцький р-н, село Волока	13	465	6682

Рисунок 2.11 – Спільні адреси з найбільшою кількістю пар

Найбільше пар (208 530) дає неповна адреса «місто Кіровоград(п)» без вулиці: на неї записано 210 юридичних осіб і 992 ФОП. Далі йдуть адреси сіл Чернівецької області, де адреса суб'єкта часто складається лише з назви населеного пункту. Отже, перетин адрес відображає не лише реальні офіси спільного використання, а й неповноту адрес у реєстрі. Запити з'єднання найдовші в роботі (101,7 і 140,5 с), бо читають обидві таблиці (3,0–3,3 ГБ) і перерозподіляють дані між редюсерами за ключем з'єднання.

2.4 Партиціювання

Для коректного порівняння створено базову керовану таблицю `uo_plain` – копію `uo_table` у тому ж форматі, що й оптимізовані таблиці (текстовий формат Nive без лапок), але без партицій і бакетів (лістинг 2.10). Порівняння з нею показує саме ефект партиціювання чи бакетингу, а не різницю між `OpenCSVSerde` і стандартним форматом.

Лістинг 2.10 – Базова керована таблиця uo_plain

```
DROP TABLE IF EXISTS uo_plain;

CREATE TABLE uo_plain
STORED AS TEXTFILE
AS
SELECT *
FROM uo_table
```

Керовану таблицю uo_part партиціоновано за станом юридичної особи (лістинг 2.11). Партиції створюються динамічно під час INSERT INTO ... SELECT (лістинг 2.12): Hive бере значення stan з останньої колонки запиту. Режим nonstrict потрібен, оскільки єдина колонка партиціювання задається динамічно, а за замовчуванням (strict) Hive вимагає хоча б однієї статичної.

Лістинг 2.11 – Створення партиціонованої таблиці uo_part

```
DROP TABLE IF EXISTS uo_part;

CREATE TABLE uo_part (
    name      STRING,
    edrpou    STRING,
    address   STRING,
    boss      STRING,
    founders  STRING,
    kved      STRING
)
PARTITIONED BY (stan STRING)
STORED AS TEXTFILE
```

Лістинг 2.12 – Наповнення таблиці uo_part

```
SET hive.exec.dynamic.partition=true;
SET hive.exec.dynamic.partition.mode=nonstrict;

INSERT INTO TABLE uo_part PARTITION (stan)
SELECT
    name,
    edrpou,
```

```

address,
boss,
founders,
kved,
stan

FROM
uo_table

```

Наповнення тривало 61 с. Кожна партиція – окрема піддиректорія `stan=<значення>` у директорії таблиці в сховищі Hive (рис. 2.12); розміри партицій відрізняються на чотири порядки: від 83,4 КБ («порушено справу про банкрутство (санація)») до 773,4 МБ («zareestrovano»).

```

$ hdfs dfs -ls -d '/user/hive/warehouse/uo_part/stan=*'
drwxr-xr-x  - hive supergroup          0 2026-10-07 22:06 /user/hive/warehouse/uo_part/stan=в стані
припинення
drwxr-xr-x  - hive supergroup          0 2026-10-07 22:06 /user/hive/warehouse/uo_part/stan=zareestr
ovano
drwxr-xr-x  - hive supergroup          0 2026-10-07 22:06 /user/hive/warehouse/uo_part/stan=zareestr
ovano, свідоцтво про державну реєстрацію недійсне
drwxr-xr-x  - hive supergroup          0 2026-10-07 22:06 /user/hive/warehouse/uo_part/stan=порушено
справу про банкрутство
drwxr-xr-x  - hive supergroup          0 2026-10-07 22:06 /user/hive/warehouse/uo_part/stan=порушено
справу про банкрутство (санація)
drwxr-xr-x  - hive supergroup          0 2026-10-07 22:06 /user/hive/warehouse/uo_part/stan=припинен
о
drwxr-xr-x  - hive supergroup          0 2026-10-07 22:06 /user/hive/warehouse/uo_part/stan=скасован
о
$ hdfs dfs -du -s -h '/user/hive/warehouse/uo_part/stan=*'
72.2 M   72.2 M   /user/hive/warehouse/uo_part/stan=в стані припинення
773.4 M  773.4 M  /user/hive/warehouse/uo_part/stan=zareestrovano
25.7 M   25.7 M  /user/hive/warehouse/uo_part/stan=zareestrovano, свідоцтво про державну реєстрацію
недійсне
1.0 M    1.0 M    /user/hive/warehouse/uo_part/stan=порушено справу про банкрутство
83.4 K   83.4 K   /user/hive/warehouse/uo_part/stan=порушено справу про банкрутство (санація)
186.9 M  186.9 M  /user/hive/warehouse/uo_part/stan=припинено
2.6 M    2.6 M    /user/hive/warehouse/uo_part/stan=скасовано

```

Рисунок 2.12 – Піддиректорії партицій таблиці `uo_part` у HDFS

Для порівняння продуктивності виконано запит з фільтром за ключем партиціювання (лістинг 2.13) до трьох таблиць; результати наведено на рис. 2.13.

Лістинг 2.13 – Запит з фільтром за станом юридичної особи

```

SELECT

COUNT(*) AS companies

```

```

FROM

    uo_part

WHERE 1=1

    AND stan = 'порушено справу про банкрутство'

```

```

median 30.08s (runs: 23.62, 31.84, 30.08), HDFS read 1.1 GB | SELECT COUNT(*) AS companies FROM uo_table WHERE 1=1 AND stan = 'порушено справу про банкрутство'
median 25.32s (runs: 25.07, 25.57, 25.32), HDFS read 1.1 GB | SELECT COUNT(*) AS companies FROM uo_plain WHERE 1=1 AND stan = 'порушено справу про банкрутство'
median 23.92s (runs: 24.03, 23.92, 23.48), HDFS read 1.0 MB | SELECT COUNT(*) AS companies FROM uo_part WHERE 1=1 AND stan = 'порушено справу про банкрутство'

```

	median, s	HDFS read, MB
uo_table	30.08	1144.6
uo_plain	25.32	1115.9
uo_part	23.92	1.0

Рисунок 2.13 – Час виконання та обсяг прочитаних даних для запиту за stan

2.5 Бакетинг

Таблицю `uo_bucket` розподілено на 10 бакетів за кодом ЄДРПОУ (лістинги 2.14, 2.15). Параметр `hive.enforce.bucketing`, вказаний у завданні, не використовується: у HIVE 2.0 його вилучено, і запис у таблицю з бакетами завжди розподіляє рядки за хешем. Властивість `bucketing_version = 1` обрано свідомо: у HIVE 3 за замовчуванням використовується версія 2 (хеш Murmur3), але `TABLESAMPLE` на рушії MapReduce обчислює бакет старою хеш-функцією й для таблиць версії 2 повертає порожній результат.

Лістинг 2.14 – Створення таблиці з бакетами `uo_bucket`

```

DROP TABLE IF EXISTS uo_bucket;

CREATE TABLE uo_bucket (
    name      STRING,
    edrpou    STRING,
    address   STRING,
    boss      STRING,
    founders  STRING,
    kved      STRING,

```

```

        stan      STRING
    )
    CLUSTERED BY (edrpou) INTO 10 BUCKETS
    STORED AS TEXTFILE
    TBLPROPERTIES ("bucketing_version" = "1")

```

Лістинг 2.15 – Наповнення таблиці uo_bucket

```

INSERT INTO TABLE uo_bucket
SELECT
    name,
    edrpou,
    address,
    boss,
    founders,
    kved,
    stan

FROM
    uo_table

```

Наповнення тривало 75 с. Кожен бакет – окремий файл 00000N_0 (рис. 2.14); розміри файлів майже однакові (110,0–113,2 МБ), тобто хеш розподіляє унікальні коди рівномірно. Директорія .hive-staging_* – тимчасова директорія запиту, яку Ніве видаляє після закриття сесії; при читанні таблиці вона ігнорується.

```

$ hdfs dfs -ls -h /user/hive/warehouse/uo_bucket
Found 11 items
drwxr-xr-x - hive supergroup 0 2026-10-07 22:12 /user/hive/warehouse/uo_bucket/.hive-stagi
ng_hive_2026-10-07_22-10-49_975_8567143884801938769-1
-rw-r--r-- 1 hive supergroup 111.6 M 2026-10-07 22:11 /user/hive/warehouse/uo_bucket/000000_0
-rw-r--r-- 1 hive supergroup 111.8 M 2026-10-07 22:11 /user/hive/warehouse/uo_bucket/000001_0
-rw-r--r-- 1 hive supergroup 112.5 M 2026-10-07 22:11 /user/hive/warehouse/uo_bucket/000002_0
-rw-r--r-- 1 hive supergroup 110.9 M 2026-10-07 22:11 /user/hive/warehouse/uo_bucket/000003_0
-rw-r--r-- 1 hive supergroup 111.0 M 2026-10-07 22:11 /user/hive/warehouse/uo_bucket/000004_0
-rw-r--r-- 1 hive supergroup 113.2 M 2026-10-07 22:11 /user/hive/warehouse/uo_bucket/000005_0
-rw-r--r-- 1 hive supergroup 112.0 M 2026-10-07 22:11 /user/hive/warehouse/uo_bucket/000006_0
-rw-r--r-- 1 hive supergroup 110.0 M 2026-10-07 22:11 /user/hive/warehouse/uo_bucket/000007_0
-rw-r--r-- 1 hive supergroup 111.1 M 2026-10-07 22:11 /user/hive/warehouse/uo_bucket/000008_0
-rw-r--r-- 1 hive supergroup 111.8 M 2026-10-07 22:11 /user/hive/warehouse/uo_bucket/000009_0

```

Рисунок 2.14 – Файли бакетів таблиці uo_bucket у HDFS

Точковий запит за кодом ЄДРПОУ (лістинг 2.16) виконано до трьох таблиць (рис. 2.15).

Лістинг 2.16 – Точковий запит за кодом ЄДРПОУ

```

SELECT
    name,
    edrpou,
    stan

FROM
    uo_bucket

WHERE 1=1
      AND edrpou = '00223941'

```

```

median 26.95s (runs: 26.95, 27.64, 26.42), HDFS read 1.1 GB | SELECT name, edrpou, stan FROM uo_table
WHERE 1=1 AND edrpou = '00223941'
median 22.90s (runs: 22.91, 22.85, 22.90), HDFS read 1.1 GB | SELECT name, edrpou, stan FROM uo_plain
WHERE 1=1 AND edrpou = '00223941'
median 22.05s (runs: 22.05, 22.26, 21.83), HDFS read 1.1 GB | SELECT name, edrpou, stan FROM uo_bucke
t WHERE 1=1 AND edrpou = '00223941'

```

	median, s	HDFS read, MB
uo_table	26.95	1144.5
uo_plain	22.90	1115.9
uo_bucket	22.05	1115.9

Рисунок 2.15 – Час виконання та обсяг прочитаних даних для точкового запиту

Віртуальна колонка `INPUT__FILE__NAME` показує файл, з якого прочитано запис (рис. 2.16): `000005_0`, тобто бакет 6.

```

[22.01s, HDFS read 1.1 GB] SELECT INPUT__FILE__NAME AS file, edrpou FROM uo_bucket WHERE 1=1 AND edrpou = '00223941'

```

	file	edrpou
0	hdfs://namenode:9000/user/hive/warehouse/uo_bucket/000005_0	00223941

Рисунок 2.16 – Файл бакета, що містить шуканий запис

Конструкція `TABLESAMPLE` (лістинг 2.17) обчислює хеш `edrpou` для кожного рядка і повертає лише рядки бакета 6. Запис повернуто (рис. 2.17), тобто обчислений бакет збігся з файлом, у який Hіve записав його під час вставки. Проте обсяг прочитаних даних не зменшився.

Лістинг 2.17 – Вибірка одного бакета

```

SELECT
    name,
    edrpou,
    stan

FROM
    uo_bucket TABLESAMPLE(BUCKET 6 OUT OF 10 ON edrpou)

WHERE 1=1
    AND edrpou = '00223941'

```

[22.42s, HDFS read 1.1 GB] SELECT name, edrpou, stan FROM uo_bucket TABLESAMPLE(BUCKET 6 OUT OF 10 ON edrpou) WHERE 1=1 AND ...

	name	edrpou	stan
0	АКЦІОНЕРНЕ ТОВАРИСТВО "ДАШУКІВСЬКІ БЕНТОНІТИ"	00223941	zareestrovano

median 22.89s (runs: 21.21, 22.89, 23.45), HDFS read 1.1 GB | SELECT name, edrpou, stan FROM uo_bucket TABLESAMPLE(BUCKET 6 OUT OF 10 ON edrpou) WHERE 1=1 AND ...

	median, s	HDFS read, MB
uo_table	26.95	1144.5
uo_plain	22.90	1115.9
uo_bucket	22.05	1115.9
uo_bucket TABLESAMPLE	22.89	1115.9

Рисунок 2.17 – Результат і час виконання запиту з TABLESAMPLE

2.6 Задача WordCount

Файл логів HDFS завантажено в директорію /wordcount/input (рис. 2.18).

```

$ hdfs dfs -mkdir -p /wordcount/input
$ hdfs dfs -put -f /data/wordcount/HDFS.log /wordcount/input/
$ hdfs dfs -ls -h /wordcount/input
Found 1 items
-rw-r--r--  1 root supergroup      1.5 G 2026-10-07 22:19 /wordcount/input/HDFS.log

```

Рисунок 2.18 – Вхідні дані задачі WordCount у HDFS

Задачу запущено утилітою `hadoop jar` з бібліотекою прикладів Hadoop 3.1.3 тричі – з 1, 2 та 4 редюсерами, кожного разу в нову вихідну директорію (лістинг 2.18).

Лістинг 2.18 – Запуск задачі WordCount з двома редюсерами

```
hadoop jar /opt/hadoop-3.1.3/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.1.3.jar \
wordcount -D mapreduce.job.reduces=2 /wordcount/input /wordcount/output-r2
```

Журнал виконання задачі з двома редюсерами наведено на рис. 2.19, основні лічильники – у табл. 2.2. Вхідний файл розбито на 12 сплітів – по одному на блок HDFS, тому запущено 12 тар-задач; задача завершилася за ≈ 62 с.

```
$ hadoop jar /opt/hadoop-3.1.3/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.1.3.jar wordcount -D mapreduce.job.reduces=2 /wordcount/input /wordcount/output-r2
2026-10-07 22:20:27,028 INFO client.RMProxy: Connecting to ResourceManager at resourcemanager/172.18.0.4:8032
2026-10-07 22:20:27,199 INFO client.AHSProxy: Connecting to Application History server at historyserver/172.18.0.6:10200
2026-10-07 22:20:27,380 INFO mapreduce.JobResourceUploader: Disabling Erasure Coding for path: /tmp/hadoop-yarn/staging/root/.staging/job_1791409673690_0049
2026-10-07 22:20:27,591 INFO input.FileInputFormat: Total input files to process : 1
2026-10-07 22:20:27,655 INFO mapreduce.JobSubmitter: number of splits:12
2026-10-07 22:20:27,785 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1791409673690_0049
2026-10-07 22:20:27,785 INFO mapreduce.JobSubmitter: Executing with tokens: []
2026-10-07 22:20:27,955 INFO conf.Configuration: resource-types.xml not found
2026-10-07 22:20:27,956 INFO resource.ResourceUtils: Unable to find 'resource-types.xml'.
2026-10-07 22:20:28,213 INFO impl.YarnClientImpl: Submitted application application_1791409673690_0049
2026-10-07 22:20:28,244 INFO mapreduce.Job: The url to track the job: http://resourcemanager:8088/proxy/application_1791409673690_0049/
2026-10-07 22:20:28,245 INFO mapreduce.Job: Running job: job_1791409673690_0049
2026-10-07 22:20:34,327 INFO mapreduce.Job: Job job_1791409673690_0049 running in uber mode : false
2026-10-07 22:20:34,328 INFO mapreduce.Job: map 0% reduce 0%
2026-10-07 22:20:51,490 INFO mapreduce.Job: map 5% reduce 0%
2026-10-07 22:20:52,498 INFO mapreduce.Job: map 11% reduce 0%
2026-10-07 22:20:53,506 INFO mapreduce.Job: map 16% reduce 0%
2026-10-07 22:20:54,525 INFO mapreduce.Job: map 30% reduce 0%
2026-10-07 22:20:55,532 INFO mapreduce.Job: map 36% reduce 0%
2026-10-07 22:20:56,540 INFO mapreduce.Job: map 47% reduce 0%
2026-10-07 22:20:57,547 INFO mapreduce.Job: map 50% reduce 0%
2026-10-07 22:21:09,640 INFO mapreduce.Job: map 55% reduce 0%
2026-10-07 22:21:10,651 INFO mapreduce.Job: map 61% reduce 0%
2026-10-07 22:21:11,659 INFO mapreduce.Job: map 74% reduce 0%
2026-10-07 22:21:12,667 INFO mapreduce.Job: map 83% reduce 0%
2026-10-07 22:21:13,675 INFO mapreduce.Job: map 86% reduce 0%
2026-10-07 22:21:14,681 INFO mapreduce.Job: map 89% reduce 0%
2026-10-07 22:21:15,688 INFO mapreduce.Job: map 92% reduce 0%
2026-10-07 22:21:26,763 INFO mapreduce.Job: map 100% reduce 0%
2026-10-07 22:21:27,771 INFO mapreduce.Job: map 100% reduce 15%
2026-10-07 22:21:29,784 INFO mapreduce.Job: map 100% reduce 100%
2026-10-07 22:21:29,795 INFO mapreduce.Job: Job job_1791409673690_0049 completed successfully
2026-10-07 22:21:29,897 INFO mapreduce.Job: Counters: 54
```

Рисунок 2.19 – Журнал виконання задачі WordCount з двома редюсерами

Таблиця 2.2 – Лічильники задачі WordCount (2 редюсери)

Лічильник	Значення
Запущено map-задач / reduce-задач	12 / 2
Вхідних рядків (Map input records)	11 175 629
Пар (слово, 1) на виході map (Map output records)	138 554 843
Пар після combiner (Combine output records)	9 620 068
Пар на вході reduce (Reduce input records)	4 375 266
Різних слів на виході (Reduce output records)	3 585 666
Прочитано з HDFS, байт	1 578 029 282
Записано в HDFS, байт	140 118 458

Вміст вихідних директорій для різної кількості редюсерів показано на рис. 2.20: кожен редюсер записує власний файл `part-r-0000N`, а порожній файл `_SUCCESS` позначає успішне завершення задачі.

```
$ hdfs dfs -ls /wordcount/output-r1
Found 2 items
-rw-r--r--  1 root supergroup          0 2026-10-07 22:20 /wordcount/output-r1/_SUCCESS
-rw-r--r--  1 root supergroup 140118458 2026-10-07 22:20 /wordcount/output-r1/part-r-00000
$ hdfs dfs -ls /wordcount/output-r2
Found 3 items
-rw-r--r--  1 root supergroup          0 2026-10-07 22:21 /wordcount/output-r2/_SUCCESS
-rw-r--r--  1 root supergroup 69939325 2026-10-07 22:21 /wordcount/output-r2/part-r-00000
-rw-r--r--  1 root supergroup 70179133 2026-10-07 22:21 /wordcount/output-r2/part-r-00001
$ hdfs dfs -ls /wordcount/output-r4
Found 5 items
-rw-r--r--  1 root supergroup          0 2026-10-07 22:22 /wordcount/output-r4/_SUCCESS
-rw-r--r--  1 root supergroup 35030823 2026-10-07 22:22 /wordcount/output-r4/part-r-00000
-rw-r--r--  1 root supergroup 34645449 2026-10-07 22:22 /wordcount/output-r4/part-r-00001
-rw-r--r--  1 root supergroup 34908502 2026-10-07 22:22 /wordcount/output-r4/part-r-00002
-rw-r--r--  1 root supergroup 35533684 2026-10-07 22:22 /wordcount/output-r4/part-r-00003
```

Рисунок 2.20 – Вихідні файли задачі WordCount для 1, 2 та 4 редюсерів

3 АНАЛІЗ РЕЗУЛЬТАТІВ ПОРІВНЯННЯ ЧАСУ ВИКОНАННЯ ЗАПИТІВ

Зведені результати вимірювань наведено в табл. 3.1. Час – медіана трьох запусків, обсяг прочитаних даних – лічильник HDFS Read задач MapReduce.

Таблиця 3.1 – Порівняння звичайних та оптимізованих таблиць

Запит	Таблиця	Час, с	Прочитано, МБ
Фільтр за stan (партиціювання)	uo_table	30,08	1144,6
	uo_plain	25,32	1115,9
	uo_part	23,92	1,0
Точковий запит за edrpou (бакетинг)	uo_table	26,95	1144,5
	uo_plain	22,90	1115,9
	uo_bucket	22,05	1115,9
	uo_bucket, TABLESAMPLE	22,89	1115,9

Hive та PostgreSQL. Підрахунок записів у Hive триває 28–37 с проти 0,15–0,29 с у PostgreSQL, хоча обидві системи читають усі дані (PostgreSQL виконує паралельне послідовне сканування таблиці, а не бере кількість з метаданих). Різниця зумовлена накладними витратами MapReduce: кожен запит Hive – це задача YARN, для якої виділяються контейнери, запускаються JVM map- і reduce-задач, а результат записується в HDFS. Ці витрати становлять ≈ 20 с незалежно від обсягу даних. На ≈ 3 ГБ, що вміщуються в пам'ять одного сервера, реляційна СКБД значно ефективніша; Hive виправданий на обсягах, які неможливо обробити на одній машині.

Формат зберігання. Таблиця uo_table стабільно повільніша за uo_plain на 4–5 с за майже однакового обсягу даних: OpenCSVSerde розбирає лапки, екрановані символи та коми всередині полів, тоді як стандартний текстовий формат Hive лише розділяє рядок за службовим символом.

Партиціювання. Запит до uo_part з фільтром за ключем партиціювання читає лише одну піддиректорію – 1,0 МБ замість 1,1 ГБ, тобто в 1100 разів менше даних (partition pruning: Hive визначає потрібні партиції за метаданими ще до запуску задачі). Проте час скорочується лише на 1,4 с порівняно з uo_plain, бо його основну частину становлять фіксовані витрати

на запуск задачі MapReduce. На більших даних виграш зростає пропорційно обсягу пропущених партицій.

Бакетинг. Точковий запит до `uo_bucket` виконується так само, як до `uo_plain`: обидва читають 1,1 ГБ, а різниця в межах розкиду вимірювань. На рушії MapReduce Hive 3.1.3 не відсікає бакети ні за умовою `WHERE` (bucket pruning реалізовано лише для рушія Tez), ні в `TABLESAMPLE`, який читає всі файли й відбирає рядки за хешем. Бакетинг дає переваги в інших сценаріях: з'єднання таблиць, розбитих на бакети за ключем з'єднання (bucket map join, sort-merge-bucket join), без повного перерозподілу даних; вибірки для аналізу; рівномірний розподіл даних за колонкою з великою кількістю значень, де партиціювання створило б мільйони дрібних директорій.

4 АНАЛІЗ РОЗПОДІЛУ СЛІВ МІЖ ВИХІДНИМИ ФАЙЛАМИ

Розподіл слів між файлами `part-r-*` для різної кількості редюсерів наведено на рис. 4.1 і в табл. 4.1.

		words	occurrences	words, %
reducers	part			
1	part-r-00000	3585666	138554843	100.0
2	part-r-00000	1791230	68658022	50.0
	part-r-00001	1794436	69896821	50.0
4	part-r-00000	895736	38982586	25.0
	part-r-00001	892027	30076772	24.9
	part-r-00002	895494	29675436	25.0
	part-r-00003	902409	39820049	25.2

Рисунок 4.1 – Кількість різних слів і входжень у кожному вихідному файлі

Таблиця 4.1 – Розподіл слів між вихідними файлами

Редюсерів	Файл	Різних слів	Частка, %	Входжень
1	part-r-00000	3 585 666	100,0	138 554 843
2	part-r-00000	1 791 230	50,0	68 658 022
	part-r-00001	1 794 436	50,0	69 896 821
4	part-r-00000	895 736	25,0	38 982 586
	part-r-00001	892 027	24,9	30 076 772
	part-r-00002	895 494	25,0	29 675 436
	part-r-00003	902 409	25,2	39 820 049

Ключ потрапляє до редюсера з номером $(\text{hash}(\text{key}) \& \text{Integer.MAX_VALUE}) \bmod R$, де R – кількість редюсерів (HashPartitioner). З цього випливають такі властивості розподілу.

1. Кожне слово потрапляє рівно в один файл: для всіх трьох запусків жодне слово не повторюється між файлами, а загальні кількості різних слів (3 585 666) і входжень (138 554 843) однакові (рис. 4.2). Результат не залежить від кількості редюсерів, змінюється лише його розбиття на файли.
2. Файли майже рівні за кількістю різних слів (50/50 при двох редюсерах, $25\% \pm 0,2\%$ при чотирьох), бо хеш рівномірно розподіляє велику кількість ключів.
3. За кількістю входжень файли нерівні: при чотирьох редюсерах – від 29,7 до 39,8 млн. Розподіляються ключі, а не їхня частота, тому часті слова зосереджують велику кількість входжень в одному файлі. Наприклад, слово INFO (10,8 млн входжень, рис. 4.4) повністю належить одному редюсеру. На даних з сильною асиметрією частот це призводить до нерівномірного навантаження редюсерів.

4. Усередині кожного файлу слова відсортовані (рис. 4.3): на етапі shuffle and sort кожен редюсер отримує свої ключі впорядкованими. Між файлами порядку немає – сусідні в алфавітному порядку слова опиняються в різних файлах.

	distinct words	words in >1 part	total occurrences
reducers			
1	3585666	0	138554843
2	3585666	0	138554843
4	3585666	0	138554843

Рисунок 4.2 – Перевірка цілісності результатів для різної кількості редюсерів

	part	word	count
0	part-r-00000	/10.250.10.100	10393
1	part-r-00000	/10.250.10.100:	1755
2	part-r-00000	/10.250.10.100:32771	2
3	part-r-00000	/10.250.10.100:32780	1
4	part-r-00000	/10.250.10.100:32784	1
5	part-r-00000	/10.250.10.100:32786	1
6	part-r-00000	/10.250.10.100:32810	2
7	part-r-00000	/10.250.10.100:32816	1
1791230	part-r-00001	/10.250.10.100:32776	2
1791231	part-r-00001	/10.250.10.100:32792	1
1791232	part-r-00001	/10.250.10.100:32796	1
1791233	part-r-00001	/10.250.10.100:32802	1
1791234	part-r-00001	/10.250.10.100:32811	1
1791235	part-r-00001	/10.250.10.100:32822	1
1791236	part-r-00001	/10.250.10.100:32844	1
1791237	part-r-00001	/10.250.10.100:32853	1

Рисунок 4.3 – Початок кожного вихідного файлу (2 редюсери)

	part	word	count
0	part-r-00001	INFO	10812836
1	part-r-00000	block	6995672
2	part-r-00001	081111	5362327
3	part-r-00000	081110	4934281
4	part-r-00000	to	3942855
5	part-r-00000	BLOCK*	3700245
6	part-r-00001	dfs.FSNamesystem:	3700245
7	part-r-00000	size	3435615
8	part-r-00000	dfs.DataNode\$PacketResponder:	3413350
9	part-r-00001	67108864	3227002
10	part-r-00001	is	3115926
11	part-r-00001	added	3115915
12	part-r-00000	of	3109850
13	part-r-00000	dfs.DataNode\$DataXceiver:	2518678
14	part-r-00000	for	1830791

Рисунок 4.4 – Найчастіші слова в логах HDFS

Combiner (локальна агрегація на стороні map) зменшує обсяг даних для shuffle: замість 138,6 млн пар (слово, 1) до редюсерів надходить 4,4 млн пар (табл. 2.2). Збільшення кількості редюсерів розпаралелює фазу reduce і зменшує розмір кожного вихідного файлу (140 МБ при одному редюсері, ≈ 70 МБ при двох, ≈ 35 МБ при чотирьох), але не зменшує загальний обсяг роботи. Стандартний WordCount розбиває текст лише за пробілами, тому до «слів» належать і числа, ідентифікатори блоків та IP-адреси з портами (наприклад, /10.250.10.100:32771); саме вони утворюють більшість із 3,59 млн різних слів.

ВИСНОВКИ

У роботі розгорнуто кластер Hadoop 3.1.3 та Hive 3.1.3 у Docker і виконано повний цикл обробки даних Єдиного державного реєстру: завантаження в HDFS, створення таблиць, аналітичні запити, оптимізацію зберігання та задачу MapReduce.

Робота з HDFS показала блокову організацію файлової системи: файл UO.csv розміром 1,2 ГБ зберігається у 9 блоках по 128 МБ, метадані про які містить NameNode, а самі блоки – DataNode.

Зовнішні таблиці Hive з OpenCSVSerde дозволили виконувати SQL-запити до CSV-файлів без їх копіювання. Віконна функція ROW_NUMBER () виявила адреси масової реєстрації (найбільша – Київ, вул. Мельникова, 12, з 2187 юридичними особами), а з'єднання за адресою – 122 917 адрес, спільних для юридичних осіб і ФОП, серед яких багато неповних адрес.

Порівняння з PostgreSQL показало, що на даних обсягом ≈ 3 ГБ Hive на MapReduce повільніший на два порядки (28–37 с проти 0,15–0,29 с) через фіксовані накладні витрати на запуск задачі ≈ 20 с; переваги Hive проявляються на даних, що не вміщуються на одну машину.

Партиціювання скоротило обсяг прочитаних даних у 1100 разів (1,0 МБ замість 1,1 ГБ) для запитів з фільтром за ключем партиціювання, хоча час через накладні витрати MapReduce змінився мало. Бакетинг рівномірно розподілив дані на 10 файлів, але не прискорив точкові запити: Hive 3.1.3 на MapReduce не відсікає бакети. Його переваги реалізуються в з'єднаннях за ключем бакетування та в рушії Tez.

Задача WordCount на 1,5 ГБ логів HDFS виконалася 12 map-задачами (по одній на блок), а combiner скоротив обсяг даних для shuffle з 138,6 до 4,4 млн пар. Слова розподіляються між редюсерами за хешем ключа: кожне слово потрапляє рівно в один файл, файли рівні за кількістю різних слів, але не за кількістю входжень, а підсумковий результат не залежить від кількості редюсерів.

СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ

- [1] Міністерство юстиції України. «Єдиний державний реєстр юридичних осіб, фізичних осіб-підприємців та громадських формувань: виванта-

ження від 08.04.2022», дата зверн. 7 жовт. 2026. url: <https://web.archive.org/web/20220413051017/https://nais.gov.ua/files/general/2022/04/08/20220408144948-25.zip>.

- [2] J. Zhu, S. He, P. He, J. Liu and M. R. Lyu, «Loghub: A Large Collection of System Log Datasets for AI-driven Log Analytics», в *2023 IEEE 34th International Symposium on Software Reliability Engineering (ISSRE)*, 2023. DOI: 10.1109/ISSRE59848.2023.00071.

ДОДАТОК А. ПРОГРАМНИЙ КОД

Повний програмний код лабораторної роботи розміщено в репозиторії <https://github.com/nuinashco/iasa-bigdata>, директорія `labs/001-hadoop-and-hive`:

- `draft.ipynb` – ноутбук Jupyter з усіма кроками роботи та результатами виконання;
- `scripts/download_data.py` – завантаження та перетворення даних реєстру (додаток Б);
- `src/lab001` – допоміжні модулі для керування кластером, виконання команд Hadoop та запитів до Hive і PostgreSQL;
- `infra` – конфігурація кластера (Docker Compose, налаштування Hadoop і Hive).

Ноутбук відтворює роботу повністю: запуск «Run All» розгортає кластер, завантажує дані та виконує всі запити (≈ 35 хв).

ДОДАТОК Б. СКРИПТ ЗАВАНТАЖЕННЯ ДАНИХ

Лістинг Б.1 – Скрипт `download_data.py`

```
"""Download the EDR registry (legal entities + sole proprietors) and convert
it to CSV.

Source: the last open-data dump of the Unified State Register ЄДР() published
by
NAIS (nais.gov.ua) on 2022-04-08, retrieved from the Internet Archive. Later
dumps
(data.gov.ua, 2026+) no longer contain ADDRESS / KVED, which the lab's queries
need.

Output (UTF-8, comma-separated, every field quoted, header row):
data/UO.csv  name, edrpou, address, boss, founders, kved, stan
data/FOP.csv fio, address, kved, stan
```

Usage:

```
python labs/001-hadoop-and-hive/scripts/download_data.py [--data-dir DIR]
[--force]
```

Does nothing if both CSVs already exist, unless --force is given.

"""

```
import argparse
import csv
import hashlib
import shutil
import sys
import time
import urllib.request
import xml.etree.ElementTree as ET
import zipfile
from concurrent.futures import ProcessPoolExecutor
from pathlib import Path
```

```
ARCHIVE_URL = (
    "https://web.archive.org/web/20220413051017id_/"
    "https://nais.gov.ua/files/general/2022/04/08/20220408144948-25.zip"
)
```

```
ARCHIVE_SHA256 = "
    c622d0817e9e252a221303e47cf7b99c439305d50692655af452e34a9ca68d72"
```

```
ARCHIVE_NAME = "edr_2022-04-08.zip"
```

```
# zip member suffix -> (output csv, [(csv column, xml tag)])
```

```
TABLES = {
    "17.1-EX_XML_EDR_UO_08.04.2022.xml": (
        "UO.csv",
        [
            ("name", "NAME"),
            ("edrpou", "EDRPOU"),
            ("address", "ADDRESS"),
            ("boss", "BOSS"),
            ("founders", "FOUNDERS"),
            ("kved", "KVED"),
            ("stan", "STAN"),
```

```

        ],
    ),
    "17.2-EX_XML_EDR_FOP_08.04.2022.xml": (
        "FOP.csv",
        [
            ("fio", "FIO"),
            ("address", "ADDRESS"),
            ("kved", "KVED"),
            ("stan", "STAN"),
        ],
    ),
)
}

DEFAULT_DATA_DIR = Path(__file__).resolve().parent.parent / "data"

def sha256(path: Path) -> str:
    h = hashlib.sha256()
    with path.open("rb") as f:
        for chunk in iter(lambda: f.read(1 << 20), b''):
            h.update(chunk)
    return h.hexdigest()

def download(dest: Path) -> None:
    if dest.exists() and sha256(dest) == ARCHIVE_SHA256:
        print(f"[download] {dest.name} already present, checksum OK")
        return
    print(f"[download] {ARCHIVE_URL}")
    tmp = dest.with_suffix(".part")
    with urllib.request.urlopen(ARCHIVE_URL, timeout=60) as resp, tmp.open("wb") as out:
        shutil.copyfileobj(resp, out, length=1 << 20)
    if (digest := sha256(tmp)) != ARCHIVE_SHA256:
        tmp.unlink()
        sys.exit(f"[download] checksum mismatch: got {digest}")
    tmp.rename(dest)
    print(f"[download] saved {dest} ({dest.stat().st_size / 1e6:.0f} MB)")

```

```

def clean(text: str) -> str:
    # One record per line for Hive's TextInputFormat; backslash is
    # OpenCSVSerde's escape char.
    return " ".join(text.replace("\\", "/").split())

def field_text(elem: ET.Element | None) -> str:
    if elem is None:
        return ""
    children = list(elem)
    if children: # multi-valued, e.g. <FOUNDERS><FOUNDER>..</FOUNDER>...</
FOUNDERS>
        return " | ".join(clean(c.text or "") for c in children)
    return clean(elem.text or "")

def convert(archive: Path, member: str, out_path: Path, columns: list[tuple[
str, str]]) -> int:
    started = time.monotonic()
    rows = 0
    tmp = out_path.with_suffix(".part")
    with zipfile.ZipFile(archive) as zf, zf.open(member) as src, tmp.open("w",
newline="", encoding="utf-8") as dst:
        writer = csv.writer(dst, quoting=csv.QUOTE_ALL, lineterminator="\n")
        writer.writerow([col for col, _ in columns])
        for _, elem in ET.iterparse(src, events=("end",)):
            if elem.tag != "RECORD":
                continue
            writer.writerow([field_text(elem.find(tag)) for _, tag in columns
])
            elem.clear()
            rows += 1
    tmp.rename(out_path)
    print(f"[convert] {out_path.name}: {rows:,} rows in {time.monotonic() -
started:.0f}s")
    return rows

def main() -> None:

```

```

parser = argparse.ArgumentParser(description=__doc__, formatter_class=
argparse.RawDescriptionHelpFormatter)

parser.add_argument("--data-dir", type=Path, default=DEFAULT_DATA_DIR)
parser.add_argument("--force", action="store_true", help="re-download and
re-convert even if CSVs exist")

args = parser.parse_args()

outputs = [args.data_dir / out_name for out_name, _ in TABLES.values()]
if not args.force and all(p.exists() for p in outputs):
    print(f"[skip] {' '.join(p.name for p in outputs)} already in {args.
data_dir} (use --force to rebuild)")
    return

raw_dir = args.data_dir / "raw"
raw_dir.mkdir(parents=True, exist_ok=True)
archive = raw_dir / ARCHIVE_NAME
download(archive)

with zipfile.ZipFile(archive) as zf:
    members = {name.rsplit("/", 1)[-1]: name for name in zf.namelist()}

with ProcessPoolExecutor(max_workers=len(TABLES)) as pool:
    jobs = [
        pool.submit(convert, archive, members[suffix], args.data_dir /
out_name, columns)
        for suffix, (out_name, columns) in TABLES.items()
    ]
    for job in jobs:
        job.result()

if __name__ == "__main__":
    main()

```